Extractor de prototipos de comportamiento o perfiles

SUBGRUP-PROP11.5

Yaoyao Guo Zhang - yaoyao.guo
Alessandro Jin - alessandro.jin
Denis Roca - denis.roca
Peiyu Wang - peiyu.wang
Xiangjun Yepan - xiangjun.yepan

Versión 1.0

Índice

Casos de uso.....1
Diagrama UML..... 8
Estructuras de datos..... 9
Estructuras de datos del algoritmo.....12
Algoritmos.....13
Relación de las clases implementadas por miembro del equipo..... 16

Casos de uso

En la carpeta DOCS/ está el diagrama de casos de uso con mejor resolución.



Registrar usuario

Actor: Usuario

Comportamiento:

1) El usuario inserta un nombre, una contraseña y confirma la contraseña.
2) El sistema valida los valores y crea un nuevo usuario con el nombre y contraseña indicada.

Errores posibles y cursos alternativos:

1) Si ya existe un usuario con el nombre indicado.
2) Si la contraseña y su confirmación no coinciden.
3) Si los campos están vacíos o no cumplen con el formato (6 caracteres para contraseña y 3 para nombre de usuario).

Iniciar sesión

Actor: Usuario

Comportamiento:

1) Usuario inserta nombre y contraseña
2) Sistema valida los valores y entra en el área del usuario.

Errores posibles y cursos alternativos:

1) Si no existe usuario con el nombre insertado.
2) Si la contraseña insertada no coincide con la contraseña del usuario.
3) Si ya hay un usuario activo.

Seleccionar encuesta creada por el usuario

Actor: Usuario

Comportamiento:

1) El usuario realiza acciones con la encuesta (Modificar encuesta, Eliminar encuesta, Ver estadísticas de las respuestas de una encuesta, Ver análisis encuesta, Visualizar respuestas de la encuesta) y se va al caso de uso correspondiente.
2) El sistema muestra al usuario el contenido de la encuesta para leer.
3) Si el usuario quiere responder a su propia encuesta, puede ir al caso de uso Seleccionar encuesta para responder.

Errores posibles y cursos alternativos:

1) Si el usuario no ha iniciado sesión.

Seleccionar encuesta para responder

Actor: Usuario

Comportamiento:

1) El usuario elige una encuesta para realizar.
2) El sistema muestra al usuario el contenido de la encuesta para leer y responder.
3) El usuario puede responder preguntas yendo al caso de uso Responder pregunta, o Modificar respuesta, Eliminar respuesta.

Errores posibles y cursos alternativos:

1) Si el usuario no ha iniciado sesión.

Crear encuesta

Actor: Usuario

Comportamiento:

1) El usuario inserta un nombre de encuesta.
2) El sistema crea una encuesta vacía con el nombre indicado por el usuario y le asigna id único.
3) El usuario puede salirse de esta encuesta o empezar el caso de uso crear pregunta.

Errores posibles y cursos alternativos:

1) Nombre vacío, el sistema informa del error.
2) Si el usuario no ha iniciado sesión.
3) El usuario ya tiene una encuesta con el mismo título.

Importar encuesta

Actor: Usuario

Comportamiento:

1) El usuario elige un fichero con una encuesta.
2) El sistema carga la encuesta.

Errores posibles y cursos alternativos:

1) El fichero no tiene el formato correcto.
2) El fichero no tiene permisos de lectura.
3) No hay ningún usuario activo.
4) Títulos duplicados.

Modificar encuesta

Actor: Usuario

Comportamiento:

1) El usuario quita, crea o modifica preguntas además de modificar el título de la encuesta.
2) El usuario guarda la encuesta o sale de la encuesta sin guardarla.
3) El sistema sale de modo modificar guardando o sin guardar según haya elegido el usuario.

Errores posibles y cursos alternativos:

1) Confirmación del usuario, el usuario puede cancelar la edición.
2) En caso de modificar el título, el nuevo título no puede ser vacío.

Eliminar encuesta

Actor: Usuario

Comportamiento:

1) El usuario elimina una encuesta
2) El sistema valida y confirma la eliminación de las encuestas.

Errores posibles y cursos alternativos:

1) La encuesta no se elimina correctamente.
2) Confirmación del usuario, el usuario puede cancelar el proceso

Crear pregunta

Actor: Usuario

Comportamiento:

1) El usuario crea una pregunta de tipo elección múltiple o única, de texto libre o una cantidad numérica.
2) Se selecciona un tipo de pregunta (opción múltiple, crear pregunta múltiple, crear pregunta numérica…) e introduce el enunciado.
3) El sistema guarda la pregunta creada.

Errores posibles y cursos alternativos:

1) Preguntas de tipo elección múltiple o única, tiene menos de 2 opciones.
2) Pregunta numérica, el rango no es correcto (min >= max).
3) Pregunta numérica el rango tiene que ser entero.
4) Si el enunciado de la pregunta está vacío.

Modificar pregunta

Actor: Usuario

Comportamiento:

1) Selecciona la pregunta que se quiere modificar.
2) El usuario introduce el enunciado de la nueva pregunta siguiendo el criterio del tipo de pregunta.
3) El sistema elimina la pregunta y crea una nueva pregunta con lo que ha introducido el usuario.

Errores posibles y cursos alternativos:

1) Confirmación del usuario, el usuario puede cancelar la edición.
2) Esta pregunta no pertenece a ninguna de las encuestas del usuario.
3) Enunciado vacío o formato incorrecto.

Eliminar pregunta

Actor: Usuario

Comportamiento:

1) El usuario selecciona una pregunta que quiere eliminar, dentro que una encuesta creada por él
2) El sistema hace un pop up para que el usuario confirme que quiere eliminarla (“¿Estás seguro de que quieres eliminar la pregunta?”)
3) Si el usuario selecciona que no, nada cambia
4) Si selecciona que sí, se elimina la pregunta y todas sus respuestas, así como sus puntuaciones asociadas al usuario.

Errores posibles y cursos alternativos:

1) Confirmación del usuario, el usuario puede cancelar el proceso.

Responder pregunta

Actor: Usuario

Comportamiento:

1) El usuario selecciona la pregunta que quiere responder.
2) Dependiendo del tipo de pregunta el usuario responde con el formato correspondiente.
3) El sistema asigna la respuesta a la pregunta.

Errores posibles y cursos alternativos:

1) Si el tipo de respuesta no corresponde al tipo de pregunta.

Eliminar respuesta

Actor: Usuario

Comportamiento:

1) El usuario elimina la respuesta de la encuesta.
2) El sistema guarda el cambio en el fichero.

Errores posibles y cursos alternativos:

1) Confirmación del usuario, el usuario puede cancelar el proceso.
2) La respuesta no es del usuario actual.

Modificar respuesta

Actor: Usuario

Comportamiento:

1) El usuario modifica la respuesta de la encuesta, introduciendo su nueva respuesta.
2) El sistema valida y guarda el cambio en el fichero.

Errores posibles y cursos alternativos:

1) Confirmación del usuario, el usuario puede cancelar la edición.
2) La respuesta no corresponde con el tipo de respuesta de esa pregunta.
3) La respuesta no es del usuario actual.

Importar respuestas

Actor: Usuario

Comportamiento:

1) El usuario elige un fichero con las respuestas de una encuesta identificada por su título y autor.
2) El sistema carga las respuestas.

Errores posibles y cursos alternativos:

1) El fichero no tiene el formato correcto.
2) El fichero no tiene permisos de lectura.

Ver respuestas de la encuesta

Actor: Usuario

Comportamiento:

1) El usuario selecciona ver respuestas de la encuesta.

2) El sistema le mostrará al usuario todas las respuestas de esa encuesta (si no tiene respuestas, mostrará una pantalla vacía).

Errores posibles y cursos alternativos:

1) El creador de la encuesta no es el usuario actual.

Ver análisis encuesta

Actor: Usuario

Comportamiento:

1) El usuario elige entre el algoritmo de kmeans, kmeans++ o el kmedoids.
2) El usuario introduce k (número de grupos por los que divide el usuario).
3) El sistema muestra los perfiles de esa encuesta y los usuarios que pertenecen a ella junto a la calidad del clustering.

Errores posibles y cursos alternativos:

1) La encuesta tiene menos de 2 usuarios que han respondido a la encuesta.
2) La k es mayor que el número de usuarios que han respondido.
3) La k es menor a 2.

Acceder a encuestas respondidas

Actor: Usuario

Comportamiento:

1) El usuario selecciona la encuesta a la que quiere acceder
2) El usuario puede modificar o borrar respuestas, es decir, que se comienza el caso de uso Modificar respuesta

Errores posibles y cursos alternativos:

1) Si el usuario no ha iniciado sesión.

Salir de la aplicación

Actor: Usuario

Comportamiento:

1) El sistema se cierra.

Errores posibles y cursos alternativos:

1) No se ha acabado de modificar (encuesta, pregunta, respuesta…).

Modificar contraseña

Actor: Usuario

Comportamiento:

1) El usuario introduce la contraseña nueva dos veces.

Errores posibles y cursos alternativos:

1) La contraseña no tiene el formato correcto (nueva contraseña no vacía y al menos tiene que tener 6 caracteres).
2) Las dos contraseñas introducidas no coinciden.
3) Si el usuario no ha iniciado sesión.

Cerrar sesión

Actor: Usuario

Comportamiento:

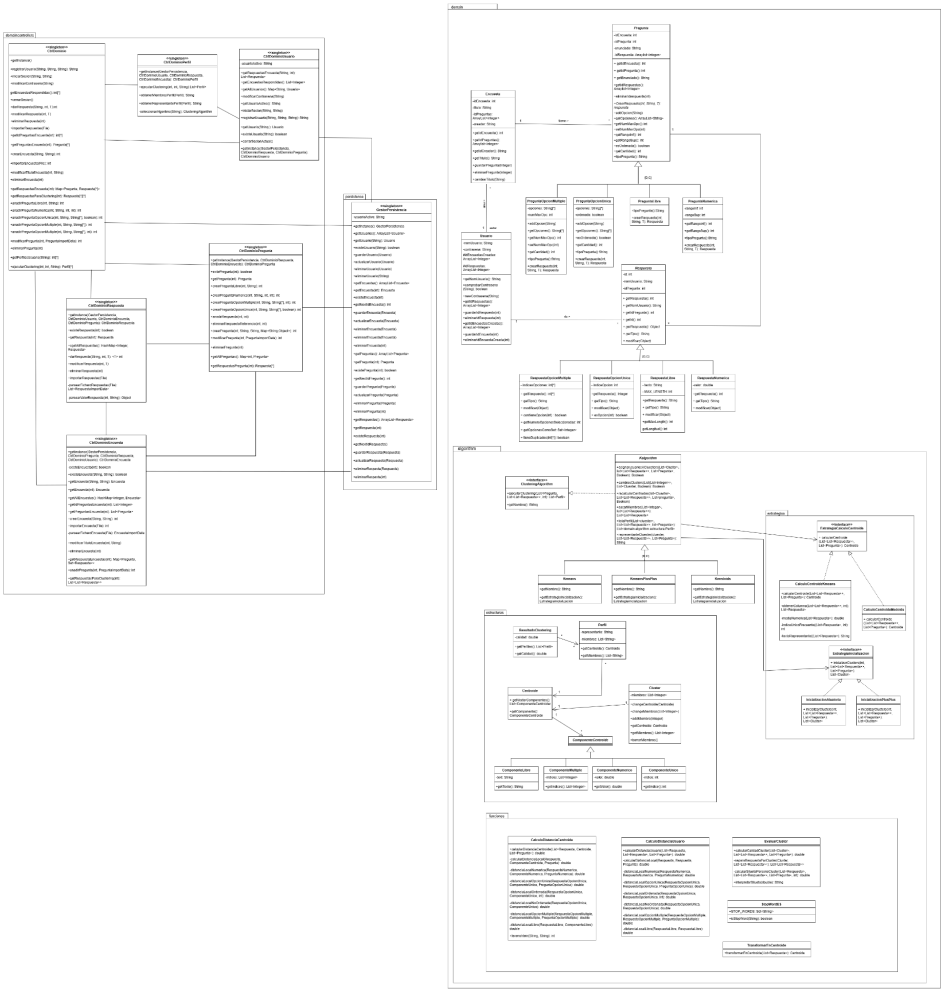
1) Se cierra la sesión del usuario activo

Errores posibles y cursos alternativos:

1) Si el usuario no está activo.

Diagrama UML

En la carpeta DOCS/ está el diagrama UML con mejor resolución.



Restricciones textuales

- RT0: Claves primarias: (Usuario, nomUsuario), (Encuesta, idEncuesta), (Respuesta, id), (Pregunta, idPregunta)
- RT1: El tipo de la pregunta de una respuesta es del mismo tipo que la respuesta.
- RT2: La respuesta de una RespuestaNumérica está entre rangoInf y rangoSup (ambos valores incluidos) de la pregunta asociada.
- RT3: La respuesta de una opción única tiene que ser un número entre 0 y el número de opciones de la pregunta asociada menos uno (ambos valores incluidos).
- RT4: Las respuestas de opción múltiple tienen que ser números distintos entre 0 y el número de opciones de la pregunta asociada menos uno (ambos valores incluidos).
- RT5: numMaxOpc de una PreguntaOpcionMúltiple tiene que ser un número entre 2 y el número de opciones que tiene (ambos valores incluidos).
- RT6: El número de respuestas de una RespuestaOpciónMúltiple tiene que ser menor o igual a numMaxOpc de la pregunta asociada.
- RT7: para un mismo autor no puede haber 2 encuestas con el mismo título.

Estructuras de datos

ArrayList

Ventajas:

- Estructura de dato simple y común.
- Acceso rápido por índice: get(i), muy útil si sabemos la posición del objeto que queremos obtener.
- Mantiene el orden de inserción: importante si el orden de la lista es relevante para su utilización.
- Fácil de recorrer: se puede iterar fácilmente con for.
- Inserción rápida: añadir un objeto, se añade al final de la lista.

Coste:

- add(object): O(1) amortizado
- get(index): O(1)
- size(): O(1)
- remove(index): O(n)

Alternativas:

- LinkedList: Inserciones y borrados en O(1), acceso por índice O(n). En la mayoría de casos accedemos por índice por ello no la usamos.
- HashSet: Evita duplicados y todas las operaciones es en medio O(1), pero no se puede acceder por índice, ocupa más espacio y no mantiene el orden de las inserciones . En el código garantizamos que no haya duplicados, necesitamos en ciertos casos el orden y es interesante el acceso por índice.
- TreeSet: Características parecidas al HashSet, pero sus operaciones cuestan de media O(log n) y ocupa menos espacio que HashSet y más que TreeSet. No usamos TreeSet por los mismos motivos que con el HashSet.

Ejemplo de uso:

- En la clase Encuesta guardamos una lista de IdPreguntas, donde el orden es importante**,** ya que para preparar la matriz para la función ejecutarClustering, cada columna corresponde a una pregunta, y todas las filas (usuarios) deben coincidir en el mismo orden.
- En la clase Usuario guardamos una lista de IdRespuestas, por la razón anterior.

HashMap

Ventajas:

- Permite asociar clave -> valor.
- Acceso directo a los objetos por clave: get(key).
- Inserción y actualización rápida de los elementos: put(key, value).
- Flexible: podemos guardar valores complejos y relaciones complejas.

Coste:

- put(key, value): O(1) amortizado
- get(key): O(1) amortizado
- containsKey(key): O(1) amortizado
- remove(key): O(1) amortizado

Alternativas:

- TreeMap: las operaciones son las mismas, pero tiene un promedio de tiempo en las operaciones de O(log n). Ocupa menos memoria, pero en el proyecto nos interesa las operaciones rápidas.

Ejemplo de uso:

- Esta estructura se usa principalmente para guardar la relación clave primaria y su correspondiente objeto, por ejemplo en la persistencia lo usamos para obtener el objeto a través de su clave, para actualizarlo o eliminarlo. Nos interesa que estas operaciones sean rápidas.

HashSet

Ventajas:

- Evita elementos duplicados
- Búsqueda rápida
- Inserción eficiente
- Ideal si solo importa la existencia de un elemento, no su posición ni orden

Coste:

- add(object): O(1) amortizado
- contains(object): O(1) amortizado
- remove(object): O(1) amortizado
- size(): O(1) amortizado

Alternativas:

- ArrayList: opción muy válida, operaciones eficientes y ocupa menos memoria, pero no garantiza que se evite duplicados, que en algunos casos se necesita, también si no sabemos el índice del objeto la búsqueda es lineal, en HashSet en mucho más rápido.
- TreeSet: las operaciones son las mismas, pero tiene un promedio de tiempo en las operaciones de O(log n). Ocupa menos memoria, pero en el proyecto nos interesa las operaciones rápidas.

Ejemplo de uso:

- En la inicialización para ejecutar el algoritmo de Kmeans, necesitamos obtener k filas randoms, usando la librería Random de java, pero puede ser que nos salga la misma fila dos veces por ello miramos el tamaño del HashSet, que garantiza k filas diferentes, como son pocos elementos usamos HashSet y aceleramos las operaciones.

Estructuras de datos del algoritmo

Centroide

Una estructura formada por una lista de “ComponenteCentroide”, es una representación de valores de la clase Respuesta. En el algoritmo se crean clusters, cada clúster tiene un centroide que son las respuestas “medias” de ese grupo, dado que una instancia de Respuesta debe de tener un usuario y guardarse en el sistema, se creó está clase para usar temporalmente en el algoritmo donde solo es necesario sus valores.

Componente Centroide

Una estructura abstracta que representa globalmente todos los tipos de componentes, donde están **ComponenteNumerico**, **ComponenteLibre**, **ComponenteMultiple**, **ComponenteUnico**, corresponde cada uno a una representación de valor de las subclases de respuestas.

Cluster

Una estructura que se usa en el algoritmo de forma temporal para guardar las particiones de los usuarios, donde tiene un centroide que representa las respuestas medias de los miembros del clúster y la lista de integer, que es la fila a cual representa el usuario.

Perfil

Una estructura que representa un cluster, tiene un representante que es el usuario con respuesta más semejante al centroide, el centroide y la lista de los usuarios que pertenecen a este clúster.

ResultadoClustering

Una estructura que devuelve el clustering, donde tiene una lista de perfiles y un número que indica la calidad del clustering.

Algoritmos

Todos los algoritmos sirven para clasificar las respuestas respondidas por usuarios sobre una encuesta. Su objetivo principal es dividir a los usuarios en grupos dependiendo de la semejanza de sus respuestas.

Recibirán una matriz de respuestas, donde cada fila contiene las respuestas de un usuario diferente, y cada columna contiene todas las respuestas de una pregunta. Aparte de la matriz, también recibirán una lista con todas las preguntas de la encuesta, en el mismo orden en el que están las respuestas correspondientes en la matriz de respuestas. Además, recibirán un entero *k* indicando la cantidad de grupos (clústers) que se quieren generar.

El flujo de ejecución de un algoritmo genérico sería el siguiente: Primero recibiría los parámetros especificados anteriormente, luego haría una inicialización de los centroides de los clústers (punto medio a partir del cual se asignan los usuarios a un perfil o a otro) y entraría en un bucle que acabará en cuanto los clústers no cambien en una iteración o llegase al número máximo de iteraciones.
El bucle consiste en asignar a los usuarios a su clúster correspondiente, dependiendo del centroide que esté más cerca, cuya distancia se calcula en función de las diferencias en las respuestas entre el usuario y el centroide. Luego se recalculan los centroides a partir de la nueva disposición de grupos para la siguiente iteración del bucle.
Una vez los clústers no hayan cambiado o se haya llegado al máximo de iteraciones, se evaluará la calidad del clustering y se retornará una lista de *k* perfiles, donde hay un representante del perfil (usuario que mejor asemeja al centroide), la lista de usuarios que pertenecen a este perfil y un número entre -1 y 1 que indica la calidad del clustering.

Los distintos algoritmos tienen principalmente dos diferencias: La inicialización de centroides y la elección del nuevo centroide. A continuación se detallan las particularidades de cada algoritmo.

K-Means

El algoritmo K-Means inicializa los centroides aleatoriamente, es decir, se eligen *k* usuarios al azar como los centros de los clústers.
El cálculo de los centroides en el bucle se calcula como la lista media de respuestas de todos los usuarios de ese grupo. Esta lista media se hace asignando a cada uno de sus elementos la media de las respuestas de una misma pregunta respondidas por los usuarios del clúster cuyo centroide estamos calculando.

K-Means++

El algoritmo K-Means++ en su inicialización primero elige un usuario existente al azar y lo usa como primer centroide. Posteriormente, para elegir los *k*-1 centroides restantes, se recorren las respuestas y se calcula su distancia con el centroide más cercano a cada una de ellas. Las que tengan distancia mayor aportan un valor más grande a la suma acumulada y, por tanto, tienen mayor probabilidad de ser escogidas como nuevos centroides, ya que su peso es proporcional al cuadrado de esa distancia mínima. Este procedimiento evita que los centroides iniciales queden demasiado próximos entre sí y favorece que el algoritmo empiece con centros situados en regiones bien separadas del espacio de respuestas.
El cálculo de los centroides en el bucle es igual al del algoritmo K-Means, cambiando solo la inicialización.

K-Medoids

El algoritmo K-Medoids se inicializa como el K-Means, eligiendo *k* usuarios aleatorios para usar como centroides.
En cambio, el cálculo de centroides en el bucle es distinto, ya que el K-Medoids asigna a un usuario existente como centroide. Concretamente el usuario cuyo sumatorio de distancias entre los otros usuarios de su mismo grupo es menor.

Distancias

Para calcular la distancia entre dos respuestas, se usan fórmulas de semejanza según el tipo de variable, estos son:

- variable numérica
- variable cuantitativa no ordenada de un solo valor
- variable cuantitativa ordenada de un solo valor
- variable cuantitativa no ordenada de un conjunto de valor (1- coeficiente de semejanza de Jaccard)
- variable de string libre (distancia de Levenshtein)

Cálculo de calidad

Dado el resultado de clustering que nos devuelve el algoritmo, es necesario evaluar la calidad de esta, utilizando coeficiente de Silhouette, que calcula para cada individuo como es de similar con los miembros de su cluster en comparación con otros clústeres, la suma de todos los coeficientes dividido con el número de individuos nos da la calidad de clustering.

- Cerca de 1, los clústeres están bien separados
- Cerca de 0, se parecen en las fronteras de los clústeres

- Menor de 0, están mal asignados los individuos

Relación de las clases implementadas por miembro del equipo

Yaoyao	**Peiyu**	**Alessandro**	**Xiangjun**	**Denis**
Respuesta	Encuesta	Centroide	Usuario	Pregunta
RespuestaLibre	DriverEncuesta	Cluster	DriverUsuario	PreguntaLibre
RespuestaNumerica	TestEncuesta	ComponenteCentroide	TestCtrlDominioEncuesta	PreguntaNumerica
RespuestaOpcionMultiple	TestUsuario	ComponenteLibre	TestCtrlDominioRespuesta	PreguntaOpcionMultiple
RespuestaOpcionUnica	TestRespuestaLibre	ComponenteMultiple	CalculoCentroideMedoids	PreguntaOpcionUnica
CtrlDominio	TestRespuestaNumerica	ComponenteNumerico	TestKmedoids	DriverPregunta
CtrlDominioEncuesta	TestRespuestaOpcionMultiple	ComponenteUnico		DriverClustering
CtrlDominioPregunta	TestRespuestaOpcionUnica	Perfil		TestKmeansPlusPlus
CtrlDominioRespuesta		CalculoCentroideKmeans		
CtrlDominioUsuario		CalculoDistanciaCentroide		
DriverRespuesta		CalculoDistanciaUsuario		
KmeansPlusPlus		StopWordsES		
EstrategiaInicializacion		TransformarEnCentroide		
InicializacionPlusPlus		ClusteringAlgorithm		
		Kalgorithm		
		Kmeans		
		CtrlDominioPerfil		
		GestorPersistencia		
		TestPreguntaLibre		
		TestPreguntaNumerica		
		TestPreguntaOpcionMultiple		
		TestPreguntaOpcio		

		nUnica		
		TestCtrlDominioPregunta		
		TestCtrlDominioUsuario		
		EvaluarCluster		
		ResultadoClustering		
		InicializacionAleatoria		